

# Analýza placenty fajčiarok a nefajčiarok

Machine Learning analýza metylačných dát

Patrik Broček Rastislav Nowak

# Analýza placenty fajčiarok a nefajčiarok

---

## Výskumné otázky

### Hlavné otázky projektu

- Dá sa z placenty určiť či matka fajčila?
- Ktoré gény sú najviac ovplyvnené?
- Dá sa rekonštruovať rozdelenie kontrolných skupín?

# Dataset

---

## Dáta

- **72 fajčiarok**
  - 35 placebo vitamín C
  - 37 vitamín C
- **37 nefajčiarok**
- **714 666 klasifikačných rysov**

## Metadáta

- Vek
- Pohlavie dieťaťa
- Doba tehotenstva

## Zdroj

[Link na dataset](#)

## Typ dát

- DNA metylácia
- Vzorky placenty
- Vysokodimenzionálne dáta

# Feature Selection

---


## Redukcia dimenzionality



## Použité metódy

- Variance cutoff
- KBest Feature Selector
- Sequential Feature Selection
- Logistic Regression


# PCA analýza — Fajčiari vs nefajčiari



## Pozorovanie

- Viditeľný efekt fajčenia
- Potenciálna klasifikovateľnosť


# PCA analýza — Pohlavie



## Pozorovanie

- Pohlavie nie sú separovateľné
- Pohlavie nesúvisí s metylačným profilom placenty



# PCA analýza — Vek



## Pozorovanie

- Vek nevytvára výrazné zhluky
- Malý efekt na metylačný profil


# Logistická regresia




## Pozorovania

- Veľmi stabilný model
- Dobrá interpretovateľnosť
- Silný baseline classifier

# KNN klasifikátor




Confusion Matrix




PCA projekcia

# SVM klasifikátor




Confusion Matrix




PCA projekcia

# Random Forests




Confusion Matrix



PCA projekcia

# Killer Features

## Najdôležitejšie gény



## Sequential feature selection top features

- cg12268888

- cg04474990

- cg08913726

- cg06369090

- **cg04004205**


- cg13141983

- **cg01096688**

- cg11739758

- **cg27402634**

- **cg24714864**




PCA projekcia

# Killer Features

Multi-region chr3:156,819,071-156,819,071 1 bp.  Search [Examples](#) ⓘ Aliases



Top CpG Features (Random Forest)



**Results:** Logistic LASSO regression demonstrated the highest performance in cross-validation testing with the lowest number of input CpGs. Accuracy was greatest in external datasets when using models developed for the same platform. PSI scores in smokers only ( $n = 72$ ) were moderately correlated with maternal plasma cotinine levels. One CpG (cg27402634), with the largest coefficient in two models, was measured accurately by digital PCR compared with measurement by EPIC array ( $R^2 = 0.98$ ).

## features


- cg12268888
- cg04474990
- cg08913726

Shorey-Kendrick LE, Davis B, Gao L, Park B, Vu A, Morris CD, Breton CV, Fry R, Garcia E, Schmidt RJ, O'Shea TM, Tepper RS, McEvoy CT, Spindel ER; program collaborators for Environmental influences on Child Health Outcomes. Development and Validation of a Novel Placental DNA Methylation Biomarker of Maternal Smoking during Pregnancy in the ECHO Program. Environ Health Perspect. 2024 Jun;132(6):67005. doi: 10.1289/EHP13838. Epub 2024 Jun 17. PMID: 38885141; PMCID: PMC11218700.


- cg27402634
- cg24714864

# Rozdelenie killer features

Top 10 Features: Distributions in Non-Smokers Only (n=24)




Top 10 Features: Distributions in Smokers Only (n=72)



# Unsupervised Learning

## KMeans clustering



## Výsledky

- Model našiel:
  - 36 vzoriek
  - 36 vzoriek

## Originálne skupiny

- 35 placebo
- 37 vitamín C

# Záver



## Hlavné výsledky

- Dáta umožňujú klasifikáciu
- Random Forests dosiahli najlepšie výsledky
- Identifikovali sme významné gény
- Unsupervised learning možno približne rekonštruoval kontrolné skupiny
- Fajčenie má obojsmerný vplyv na metylačný profil placenty

## Ďakujeme za pozornosť

---

- Patrik Broček
- Rastislav Nowak